

Съдържание

Съдържание.....	2
Увод.....	3
Зареждане на данните и начален общ анализ.....	4
Едномерен анализ на променливите.....	6
Числови променливи.....	6
Анализ на Rec_Perf (Перфектно посрещане в %).....	6
Анализ на Opponent_Aces (Асове на опонента).....	9
Общо заключение за числовите променливи.....	11
Категорийни променливи.....	11
Is Winner.....	11
Match venue.....	12
Многомерен анализ и взаимодействия между променливите.....	13
Rec_Perf and Is_Winner.....	13
Opponent_Aces & Is_Winner.....	14
Is_Winner & Match_Venue.....	15
Match_Venue & Rec_Perf.....	16
Opponent_Aces & Match_Venue.....	17
Opponent_Aces & Rec_Perf.....	19
Заключение от многомерния анализ.....	20
Изграждане на модели и сравнение.....	22
Прост модел.....	22
Сложен модел.....	23
Прогнози с помощта на простия модел.....	24
Прогнози с помощта на сложния модел.....	25
Заключение.....	28

Увод

Спортът волейбол, особено на клубно ниво в елитни първенства като полската PlusLiga, се характеризира с изключително висока динамика, тактическа зрялост и интензивност на играта. В съвременния волейбол елементи като сервиз-посрещане и фактора на домакиния терен са определящи за спечелването на тактическо предимство и краен успех. Разбирането, измерването и прогнозирането на факторите, които влияят върху крайния изход от срещите, представлява тема от значителен интерес за треньори, спортни анализатори и специалисти по спортна статистика.

Основната цел на този всеобхватен статистически анализ е да проучи сложните фактори, които влияят върху вероятността за постигане на победа, като се фокусира върху ефективността на отборното посрещане (**Rec Perf**), агресивността на противниковия начален удар (**Opponent Aces**) и мястото на провеждане на срещата (**Match Venue**). Чрез този софтуерен и математически подход проектът се стреми да постигне няколко ключови цели:

- **Изследователски анализ на данни (EDA):** Да се придобие основно разбиране за структурата, разпределението и присъщите взаимоотношения в набора от данни, по-специално как разпределението на процента за перфектно посрещане и допуснатите асове варират в зависимост от крайния изход от срещата.
- **Въздействие на ситуационните и техническите променливи:** Да се оцени статистически влиянието на фактори като качеството на посрещането и мястото на провеждане на мача (домакинство/гостуване) върху стабилността на резултатите, идентифицирайки значими различия между печелившите и губещите отбори.
- **Разработване на предсказвателен модел:** Да се конструира стабилен и интерпретируем бинарен логистичен регресионен модел (BLR), способен да предсказва точно вероятността за победа въз основа на идентифицираните влиятелни фактори — агресивността на противниковия сервиз, качеството на посрещане и категорийната променлива за домакин/гост.
- **Диагностична оценка на модела:** Да се оцени строго и сравни качеството на прогнозните модели чрез информационния критерий на Akaike (AIC) и коефициента Nagelkerke R^2 , както и визуално изследване на техните вероятностни S-криви. Тази стъпка е от решаващо значение за валидиране на надеждността на изводите.

Чрез този многостранен подход проектът има за цел да предостави ясни, научно обосновани прозрения за динамиката на волейболната статистика и да предложи надеждна рамка за предсказване и оптимизиране на спортните резултати на база на реални данни.

Зареждане на данните и начален общ анализ

След намирането на [подходящи сурови данни от полската PlusLiga](#), първата стъпка е тяхното зареждане в средата RStudio и трансформирането им в подходящ формат. Тъй като в оригиналния файл данните за един мач са разположени на един ред (с променливи за Отбор 1 и Отбор 2), ние разделяме и подреждаме данните така, че всяко наблюдение да представлява представянето на конкретен отбор. По този начин можем да анализираме посрещането на даден отбор спрямо агресивността на сервиза на неговия опонент.

Първо зареждаме данните, изчистваме текстовия символ % от процентните колони и създаваме изчистен датафрейм:

```
extract_team_stats <- function(data, team_prefix, opponent_prefix, is_team_1 = TRUE) {  
  
  raw_rec <- data[[paste0(team_prefix, "_Rec_Perf")]]  
  clean_rec <- as.numeric(gsub("%", "", raw_rec))  
  
  opp_aces <- as.numeric(data[[paste0(opponent_prefix, "_Srv_Ace")]])  
  
  venue_value <- ifelse(is_team_1, "Home", "Away")  
  
  target_winner_value <- ifelse(is_team_1, 0, 1)  
  is_winner <- ifelse(data$Winner == target_winner_value, "Yes", "No")  
  
  return(data.frame(  
    Rec_Perf      = clean_rec,  
    Opponent_Aces = opp_aces,  
    Match_Venue   = as.factor(venue_value),  
    Is_Winner      = as.factor(is_winner),  
    stringsAsFactors = FALSE  
  )  
)}  
  
df_raw <- read.csv("matches.csv")  
  
t1_dataset <- extract_team_stats(df_raw, team_prefix = "T1", opponent_prefix = "T2",  
is_team_1 = TRUE)  
t2_dataset <- extract_team_stats(df_raw, team_prefix = "T2", opponent_prefix = "T1",  
is_team_1 = FALSE)  
  
df <- rbind(t1_dataset, t2_dataset)  
rownames(df) <- NULL
```

След това проверяваме типа на нашите променливи в структурирания датасет. Вижда се, че имаме две категориини променливи под формата на фактори (**Is_Winner**, която се явява нашата зависима променлива за крайния изход от мача, и **Match_Venue** за мястото

на провеждане) и две числови променливи (**Rec_Perf** и **Opponent Aces**), които ще служат като независими предиктори в прогнозните ни модели.

```
print(str(df))

'data.frame':  5278 obs. of  4 variables:
 $ Rec_Perf   : num  25 16 21 12 23 10 21 22 25 10 ...
 $ Opponent_Aces: num  10 4 9 8 12 8 0 1 4 6 ...
 $ Match_Venue : Factor w/ 2 levels "Home","Away": 1 1 1 1 1 1 1 1 1 1 ...
 $ Is_Winner   : Factor w/ 2 levels "No","Yes": 1 2 1 2 1 2 2 2 2 1 ...
```

След това гледаме обобщените данни относно нашите променливи. Лесно се забелязва, че перфектното посрещане варира в широки граници – от критично ниските 2% до отличните 56%. Противниковите асове достигат сериозни стойности в отделни мачове (максимум 115 аса), което показва наличие на мачове с изключително интензивен натиск от начален удар. Разпределението на мачовете по отношение на крайния изход и фактора домакин/гост е напълно балансирано, което гарантира статистическата стабилност на следващите анализи.

```
print(summary(df))
Rec_Perf  Opponent_Aces  Match_Venue Is_Winner
Min.   :2.00  Min.   : 0.00  Home:2639  No :2639
1st Qu.:14.00 1st Qu.: 39.25  Away:2639  Yes:2639
Median :18.00 Median : 64.00
Mean   :19.07 Mean   : 55.43
3rd Qu.:24.00 3rd Qu.: 81.00
Max.   :56.00 Max.   :115.00
```

Едномерен анализ на променливите

За да разберем по-добре структурата на нашите данни, ще изследваме всяка една от променливите самостоятелно. Този анализ ни помага да идентифицираме разпределението на данните, наличието на необичайни стойности (аутлайери) и вътрешния баланс на извадката ни.

Числови променливи

Числовите величини в нашия модел ще изследваме по три начина: чрез диаграма тип *boxplot* проверяваме за наличие на аутлайери, чрез хистограма анализираме приблизителното разпределение на честотите, а чрез теста на Шапиро-Уилк проверяваме статистически дали величините следват нормално разпределение.

Анализ на Rec_Perf (Перфектно посрещане в %)


```
par(mfrow=c(1,2))

boxplot(df$Rec_Perf,
        main="Boxplot на Rec_Perf",
        ylab="Перфектно посрещане (%)",
        col="lightblue",
        border="black")

hist(df$Rec_Perf,
     main="Хистограма на Rec_Perf",
     xlab="Перфектно посрещане (%)",
     ylab="Честота",
     col="lightgreen",
     breaks=20)

par(mfrow=c(1,1))

qqnorm(df$Rec_Perf, main="3. Q-Q Plot на Rec_Perf", col="darkblue")
qqline(df$Rec_Perf, col="red", lwd=2)
```




Анализ на boxplot-a: Медианата на перфектното посрещане се позиционира малко под 20% (около 18%), а централните 50% от данните (интерквартилният обхват между първия и третия квартил) са концентрирани стабилно между 14% и 24%. Графиката ясно идентифицира наличието на множество аутлайери (единични точки) над горния мустак, който се простира до около 39%. Тези стойности достигат до максимум 56% перфектно посрещане. В контекста на волейболната статистика това са напълно реални данни, отразяващи мачове с изключително висок процент на перфектен прием, които не следва да бъдат премахвани, тъй като носят ценна информация за модела.

Анализ на histogram-ата: Хистограмата показва едномодално разпределение с ясна дясна асиметрия. Най-висока честота (над 600 случая) се наблюдава в интервала 16%–18%. От тази модална стойност надясно разпределението формира дълга, постепенно затихваща „опашка“, която се простира чак до 56%. Тази форма е типична за спортните показатели, където средните и умерено ниските резултати са стандарт, а изключително високите стойности се срещат значително по-рядко.

Анализ на Q-Q-Plot-a: Точките следват червената линия в почти целия си диапазон, което означава, че разпределението е супер близко до нормалното. Визуалната проверка показва, че в централната си част точките следват плътно червената линия, което индикира добро приближение до нормалното разпределение в средните стойности. Отклоненията в двата края (особено в десния) обаче потвърждават влиянието на асиметрията.

3. Q-Q Plot на Rec_Perf



За финално научно потвърждение на хипотезата за нормалност прилагаме теста на Шапиро-Уилк върху представителна извадка от $N = 5000$ записа при ниво на съгласие $\alpha = 0.05$

```
shapiro.test(sample(df$Rec_Perf, 5000))
```

```
#      Shapiro-Wilk normality test
```

```
#
```

```
# data:  sample(df$Rec_Perf, 5000)
```

```
# W = 0.97409, p-value < 2.2e-16
```

Тестът на Шапиро-Уилк отхвърля нулевата хипотеза (че данните са нормално разпределени) следователно данните не са нормално разпределени.

Анализ на **Opponent_Aces** (Асове на опонента)


```
par(mfrow=c(1,2))

boxplot(df$Opponent_Aces,
        main="Boxplot на Opponent_Aces",
        ylab="Брой сервиси на противника",
        col="lightblue",
        border="black")

hist(df$Opponent_Aces,
     main="Хистограма на Opponent_Aces",
     xlab="Брой сервиси на противника",
     ylab="Честота",
     col="lightgreen",
     breaks=20)

par(mfrow=c(1,1))


qqnorm(df$Opponent_Aces, main="3. Q-Q Plot на Opponent_Aces", col="darkblue")
qqline(df$Opponent_Aces, col="red", lwd=2)
```



Анализ на boxplot-а: За разлика от предходната променлива, кутийната диаграма на **Opponent_Aces** показва абсолютно чиста извадка без нито един аутлайер. Медианата е разположена около 64 сервиси. Данните са разпределени сравнително симетрично около нея, като долният мустак достига до 0, а горният се простира до максимума от 115 сервиси. Мустаките обхващат целия диапазон на вариация на данните, което показва липса на изолирани статистически аномалии.

Анализ на histogram-ата: Хистограмата разкрива изключително специфична и интересна структура – наблюдаваме **бимодално (двувърхо) разпределение с нулева честота (празнина) в средата**.

- **Първи пик (вляво):** Наблюдава се огромно натрупване на стойности в диапазона между 0 и 10 сервиса (над 700 случая).
- **Втори пик (вдясно):** Основната маса от данни образува голямо, камбановидно разпределение с център около 60–80 сервиса, което плавно затихва към 115.
- **Празнина (между 15 и 30):** В този диапазон практически липсват данни.



Анализ на Q-Q-Plot-а: Диаграмата Q-Q plot категорично потвърждава, че променливата **НЕ следва нормално разпределение**. Наблюдава се брутално отклонение от червената референтна линия.

```
shapiro.test(sample(df$Opponent_Aces, 5000))
```

Shapiro-Wilk normality test

```
data: sample(df$Opponent_Aces, 5000)
```

```
W = 0.87038, p-value < 2.2e-16
```

Тестът на Шапиро-Уилк ни отхвърля нулевата хипотеза (че данните са нормално разпределени) потвърждава, че данните не са нормално разпределени.

Общо заключение за числовите променливи

В заключение, и двете изследвани числови величини **не са нормално разпределени**. Докато при **Rec_Perf** се наблюдава класическо дясно изкривяване с наличие на единични аутлайери, то при **Opponent_Aces** е налице комплексна бимодална структура с два ясни центъра на тежестта на данните.

Категорийни променливи

Is Winner

```
table(df$Is_Winner)
No  Yes
2639 2639

barplot(table(df$Is_Winner),
main = "Честотно разпределение на Is_Winner",
xlab = "Изход от мача (Победител)",
ylab = "Брой мачове",
col = c("tomato", "lightgreen"))
```




Честотният анализ на целевата променлива **Is_Winner** показва напълно балансирано разпределение, като категориите за загуба („No“) и победа („Yes“) съдържат абсолютно равен брой наблюдения (точно по 2639 записа или съотношение 50/50%). Това перфектно равенство отразява пълната огледална статистика на спортните резултати в извадката и осигурява оптимална и софтуерно непредубедена основа за последващото изграждане на класификационния модел.

Match venue

```
table(df$Match_Venue)

Home Away
2639 2639

barplot(table(df$Match_Venue),
        main = "Честотно разпределение на Match_Venue",
        xlab = "Място на провеждане (Домакинство)",
        ylab = "Брой мачове",
        col = c("tomato", "lightgreen"))
```



Честотният анализ на независимата категорийна променлива **Match_Venue** също показва напълно симетрично и балансирано разпределение. Двете дефинирани категории – за гостуване („Away“) и за домакинство („Home“) – съдържат абсолютно равен брой наблюдения (точно по 2639 записа за всяка категория, което формира съотношение от 50/50%). Този перфектен баланс е естествена последица от логическата структура на волейболния шампионат и на самия датасет, тъй като всяка среща задължително противопоставя точно един домакин срещу точно един гостуващ отбор. Липсата на дисбаланс в класовете предотвратява изкривяването на модела в полза на по-често срещана среда и гарантира, че **статистическият алгоритъм на логистичната регресия** ще оцени напълно обективно влиянието на фактора „домакинско предимство“ върху вероятността за постигане на краен успех.

Многомерен анализ и взаимодействия между променливите

В тази секция ще изследваме взаимодействията между променливите в нашия волейболен модел, за да установим съществуват ли статистически значими зависимости между игровите компоненти и как те влияят върху крайния изход от двубоите.


Rec_Perf and Is_Winner

```
boxplot(Rec_Perf ~ Is_Winner, data = df,
        col = c("tomato", "lightgreen"),
        main = "Посрещане спрямо Изхода от мача",
        xlab = "Победа (Is_Winner)",
        ylab = "Перфектно посрещане (%)")

wilcox.test(Rec_Perf ~ Is_Winner, data = df)

Wilcoxon rank sum test with continuity correction

data: Rec_Perf by Is_Winner
W = 3552202, p-value = 0.2053
alternative hypothesis: true location shift is not equal to 0
```



Изследваме разпределението на процента перфектно посрещане (**Rec_Perf**) в зависимост от изхода на мача (**Is_Winner**) чрез теста на Уилкоксън и сравнителен boxplot.

Получената **p-стойност от 0.2053** е значително по-голяма от стандартното ниво на съгласие $\alpha = 0.05$. Поради това **не можем да отхвърлим нулевата хипотеза** и установяваме, че няма статистически значима разлика в нивата на перфектно посрещане между спечелилите и загубилите отбори.

Това заключение се потвърждава изцяло от визуалните данни на представения boxplot. Двете кутии (за „No“ и „Yes“) са с абсолютно идентична структура – техните медиани съвпадат точно на ниво от 18%, а междуквartilните им размахвания са напълно

припокриващи се (от 14% до 24%). Наличието на outliers в горния край на разпределението за двете групи допълнително доказва липсата на локационно изместване.


Opponent_Aces & Is_Winner

```
boxplot(Opponent_Aces ~ Is_Winner, data = df,
        col = c("tomato", "lightgreen"),
        main = "Асове на противника спрямо Изхода",
        xlab = "Победа (Is_Winner)",
        ylab = "Асове на противника (брой)")

wilcox.test(Opponent_Aces ~ Is_Winner, data = df)

Wilcoxon rank sum test with continuity correction

data: Opponent_Aces by Is_Winner
W = 2878259, p-value < 2.2e-16
alternative hypothesis: true location shift is not equal to 0
```



Изследваме разпределението на броя асове на противника (**Opponent_Aces**) в зависимост от изхода на мача (**Is_Winner**) чрез теста на Уилкоксън и сравнителен boxplot.

Получената **p-стойност** е **изключително малка** ($p < 0.05$), което ни дава пълно основание да отхвърлим нулевата хипотеза. Установяваме статистически високосзначима разлика в броя на допуснатите асове при победи и загуби.

Визуалните данни от boxplot графиката ясно подкрепят този извод, показвайки сериозно разминаване между двете групи.

Анализът разкрива ясен спортен парадокс – при спечелените мачове („Yes“) отборите всъщност са изправени пред по-голям общ обем сервизи от противника (медиана около 66) в сравнение със загубените мачове („No“), където медианата е по-ниска (около 56).

Кутията за победи („Yes“) е изцяло изместена нагоре, като нейният първи квартил съвпада почти изцяло с медианата на губещите отбори. В допълнение, при групата на победителите се наблюдават единични необичайни *outliers* в долния край на разпределението, достигащи до 0.

Този резултат намира своето логично обяснение в динамиката на волейболната игра. Спечелените мачове в елитни първенства като PlusLiga често преминават през оспорвани 4-геймови или 5-геймови битки. По-голямата продължителност на победните мачове естествено дава възможност на противника да изпълни по-голям кумулативен брой сервиси в рамките на срещата. Обратно, бързите загуби (например с 0:3 гейма) ограничават времето за игра и броя на разиграванията, което рефлектира в по-ниски стойности на показателя. Този статистически факт доказва, че обемът на променливата е силно обвързан с характера на срещата, което я прави ключов компонент за прогнозния ни модел.

Is_Winner & Match_Venue

```
table_venue_winner <- table(df$Match_Venue, df$Is_Winner)
print("--- Кръстосана таблица: Match_Venue vs Is_Winner ---")
print(table_venue_winner)
```

```
      No  Yes
Home 1208 1431
Away 1431 1208
```

```
print("--- Процентно разпределение ---")
print(prop.table(table_venue_winner, margin = 1) * 100)
```


```
      No    Yes
Home 45.77491 54.22509
Away 54.22509 45.77491
```

```
chisq_test <- chisq.test(table_venue_winner)
print(chisq_test)
```

```
Pearson's Chi-squared test with Yates' continuity
correction
```

```
data: table_venue_winner
X-squared = 37.351, df = 1, p-value = 9.869e-10
```

```
barplot(table_venue_winner,
  beside = TRUE,
  legend.text = TRUE,
  args.legend = list(x = "topright"),
  main = "Влияние на домакинството върху изхода от мача",
  xlab = "Победител (Is_Winner)",
  ylab = "Брой мачове",
  col = c("coral", "skyblue"))
```



Изследваме връзката между двете категорийни променливи – място на провеждане на мача (**Match_Venue**) и изход от срещата (**Is_Winner**) – чрез кръстосана таблица, процентен анализ и Хи-квадрат тест на Пийърсън

Резултатите от теста показват **p-стойност, клоняща към нула**, което е далеч под критичното ниво на съгласие $\alpha = 0.05$. Поради това **отхвърляме нулевата хипотеза** и установяваме статистически високозначима зависимост между домакинския фактор и крайния изход от мача.

Математическият анализ на таблицата разкрива, че когато отборите играят в собствената си зала („**Home**“), вероятността им за победа нараства до **54.23%** (1431 мача) срещу 45.77% за загуба. Огледално, при гостуване („**Away**“), шансът за загуба се вдига до **54.23%** (1431 мача).

Тези данни се визуализират отлично от разделения стълбищен диаграм (grouped barplot), където ясно се вижда превъзходството на оранжевите стълбове („Home“) при спечелените мачове („Yes“) и доминирането на сините стълбове („Away“) в секцията на загубилите („No“). Налице е изразен ефект на „домакинско предимство“.

Match_Venue & Rec_Perf

```
boxplot(Rec_Perf ~ Match_Venue, data = df,
  col = c("gold", "lightblue"),
  main = "Посрещане: Домакин vs Гост",
  xlab = "Място (Match_Venue)",
```

```
ylab = "Rec_Perf (%)")
```


```
wilcox.test(Rec_Perf ~ Match_Venue, data = df)
```

Wilcoxon rank sum test with continuity correction

data: Rec_Perf by Match_Venue

W = 3714358, p-value = 2.684e-05

alternative hypothesis: true location shift is not equal to 0



Изследваме разпределението на процента перфектно посрещане (**Rec_Perf**) в зависимост от мястото на провеждане на срещата (**Match_Venue**) чрез теста на Уилкоксън и сравнителен boxplot.

Получената **p-стойност** от **2.684e-05** е изключително малка и ни дава пълно основание да отхвърлим нулевата хипотеза. Установяваме статистически значима разлика в качеството на посрещане при домакински мачове и мачове на чужд терен.

Визуалните данни от boxplot графиката ясно подкрепят този извод. Наблюдава се леко, но устойчиво локационно изместване в полза на домакините („**Home**“), чиято медиана е позиционирана на ниво от **19%**, докато при гостуващите отбори („**Away**“) тя пада на **18%**. Долната граница на кутията (първият кватил) за домакинските мачове също е по-висока (14%) в сравнение с тази при гостуванията (13%). Това доказва визуално, че факторът „собствена зала“ оказва позитивно влияние върху стабилността на посрещането на отборите

Opponent_Aces & Match_Venue

```
boxplot(Opponent_Aces ~ Match_Venue, data = df,  
        col = c("gold", "lightblue"),  
        main = "Асове на противника: Домакин vs Гост",  
        xlab = "Място (Match_Venue)",  
        ylab = "Opponent_Aces (брой)")
```


```
wilcox.test(Opponent_Aces ~ Match_Venue, data = df)
```

Wilcoxon rank sum test with continuity correction

data: Opponent_Aces by Match_Venue

W = 3573460, p-value = 0.09899

alternative hypothesis: true location shift is not equal to 0



Изследваме разпределението на броя асове на противника (**Opponent_Aces**) в зависимост от мястото на провеждане на срещата (**Match_Venue**) чрез теста на Уилкоксън и сравнителен boxplot.

Получената **p-стойност от 0.09899** е по-голяма от критичното ниво на съгласие $\alpha = 0.05$. Поради това **не можем да отхвърлим нулевата хипотеза** и приемаме, че мястото на провеждане на мача (домакинство или гостуване) не оказва статистически значимо влияние върху броя на допуснатите асове от противникова среда.

Този извод се потвърждава визуално от приложената boxplot графика. Двете кутии (за „Home“ и „Away“) изглеждат почти идентично разположени по вертикалната ос.


Медианата при домакинските мачове е съвсем малко по-висока (около 64 аса) в сравнение с тази при гостуванията (около 63 аса), а междуквartilните размахвания и дължината на „мустаците“ съвпадат в изключително висока степен. Натискът на противника от линията за начален удар остава сравнително константен фактор, независимо от това кой отбор е домакин.

Opponent_Aces & Rec_Perf

```
plot(df$Opponent_Aces, df$Rec_Perf,  
     main = "Корелация: Асове на противника спрямо Посрещане",  
     xlab = "Асове на противника (брой)",  
     ylab = "Перфектно посрещане (%)",  
     col = "darkgreen",  
     pch = 16)  
  
abline(lm(Rec_Perf ~ Opponent_Aces, data = df), col = "red", lwd = 2)  
  
cor_test <- cor.test(df$Opponent_Aces, df$Rec_Perf, method = "spearman")  
print(cor_test)
```

Spearman's rank correlation rho

data: df\$Opponent_Aces and df\$Rec_Perf
S = 2.0954e+10, p-value < 2.2e-16
alternative hypothesis: true rho is not equal to 0
sample estimates:
rho
0.1449041



Изследваме линейната зависимост между двете количествени променливи – броя асове на противника (**Opponent_Aces**) и процента перфектно посрещане (**Rec_Perf**) – чрез диаграма на разсейването (scatter plot) и коефициента на корелация на Спирман ρ .

Получената **p-стойност е изключително малка ($p < 0.05$)**, което показва, че съществува статистически значима връзка между двата показателя. Стойността на коефициента **$\rho = 0.1449$** дефинира тази връзка като **слаба и положителна**.

Визуалният анализ на scatter plot-а разкрива специфична двумодална структура на извадката, при която наблюденията се разделят на две ясно обособени групи по абсцисната ос. Първият по-малък сектор обхваща мачове с нисък брой допуснати асове (под 15), докато основният масив от данни е концентриран в зоната между 40 и 100 аса. Въпреки че червената тренд линия показва съвсем лек наклон нагоре (потвърждавайки слабата положителна корелация), облакът от точки е силно разпръснат около нея. Това доказва, че макар връзката да е реална и софтуерно доказана, вариацията в качеството на посрещане не може да бъде обяснена линейно единствено чрез интензитета на противниковия начален удар.

Заклучение от многомерния анализ

Проведеният многомерен анализ и тестването на статистически хипотези разкриха следните ключови зависимости в структурата на волейболните данни:

- **Връзка между сервиз и посрещане:** Съществува слаба, но статистически значима положителна корелация между процента перфектно посрещане (**Rec_Perf**) и натрупания брой асове на противника (**Opponent_Aces**). Това индикира тактическа адаптация на дефанзивната линия при по-дълги и оспорвани срещи срещу агресивни сървъри.
- **Ефект на домакинското предимство:** Крайният изход от срещата (**Is_Winner**) е силно обвързан с фактора домакинство (**Match_Venue**). При мачовете у дома вероятността за победа нараства до **54.23%**, което се потвърждава като високосзначима зависимост от Хи-квадрат теста.
- **Психологическо и пространствено предимство:** Тестът на Уилкоксън потвърждава, че домакинското предимство е пряко свързано с качеството на играта в дефанзива. При мачовете на собствен терен се отчита статистически по-висок процент на перфектно посрещане (медиана 19% срещу 18% при гостуване).
- **Константност на противниковия натиск:** В същото време, агресивността на противниковия начален удар (**Opponent_Aces**) не се влияе от това дали отборът е домакин или гост. Показателят обаче се явява силно диференциращ спрямо крайния изход, като при победните мачове парадоксално се регистрира по-висок брой асове поради по-голямата продължителност на спечелените срещи.

В обобщение: Крайният резултат във волейболния шампионат е статистически обусловен от домакиния фактор и интензитета на противниковия сервис. Ефектът на перфектното посрещане не се проявява като изолиран и самостоятелен фактор за победа, а функционира в комплексно взаимодействие, модулирайки се в зависимост от това дали отборът играе на собствен или на чужд терен.

Изграждане на модели и сравнение

Въз основа на многомерния анализ установихме, че броят асове на противника (**Opponent_Aces**) има статистически високославно влияние върху изхода от мача, като при спечелените срещи парадоксално се наблюдава по-висок брой допуснати асове (медиана 66) в сравнение със загубените (медиана 56). Тъй като зависимата променлива (**Is_Winner**) е бинарна („Yes“ / „No“), класическата линейна регресия е неприложима, тъй като би нарушила изискванията за нормалност и би допуснала абсурдни прогнози извън логическия интервал [0, 1]. Ето защо преминаваме към **Бинарна логистична регресия (BLR)** с цел да изчислим точната вероятност за победа; чрез своята функция тя гарантира, че прогнозираните стойности винаги ще останат заключени строго между 0% и 100%.

Прост модел

```
modell <- glm(Is_Winner ~ Opponent_Aces, data = df, family = "binomial")
summary(modell)
```

Call:

```
glm(formula = Is_Winner ~ Opponent_Aces, family = "binomial",
    data = df)
```

Coefficients:

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-0.4017634	0.0570765	-7.039	1.94e-12 ***
Opponent_Aces	0.0072366	0.0008962	8.075	6.74e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

Null deviance: 7316.9 on 5277 degrees of freedom

Residual deviance: 7250.8 on 5276 degrees of freedom

AIC: 7254.8

Number of Fisher Scoring iterations: 4

Променливата е сигурен фактор: Наличието на три звездички (***) до броя асове на противника (**Opponent_Aces**) ни показва, че този показател е статистически значим. Връзката не е случайна – противниковият сервис оказва сериозно влияние върху това дали ще спечелим, или ще загубим. Тъй като стойността на коефициента е положително число (0.0072), моделът потвърждава интересна волейболна тенденция – с увеличаването на броя допуснати асове, вероятността за победа на нашия отбор всъщност нараства. Информационният критерий на Akaike за този модел е **AIC = 7254.8**.

Сложен модел

```
model2 <- glm(Is_Winner ~ Opponent_Aces + Rec_Perf + Match_Venue, data = df, family =
"binomial")
summary(model2)
```

Call:

```
glm(formula = Is_Winner ~ Opponent_Aces + Rec_Perf + Match_Venue,
    family = "binomial", data = df)
```

Coefficients:

```
              Estimate Std. Error z value Pr(>|z|)
(Intercept)  -0.0926638  0.0944766  -0.981   0.3267
Opponent_Aces  0.0072906  0.0009017   8.086 6.18e-16 ***
Rec_Perf      -0.0074473  0.0037461  -1.988   0.0468 *
Match_VenueAway -0.3404607  0.0557191  -6.110 9.94e-10 ***
```

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

Null deviance: 7316.9 on 5277 degrees of freedom
Residual deviance: 7210.6 on 5274 degrees of freedom
AIC: 7218.6

Number of Fisher Scoring iterations: 4

Opponent_Aces (три звездички ***): Остава изключително важен фактор. Плюсът пред числото се запазва (0.0073), което означава, че дори когато отчитаме другите фактори, повечето асове на противника все още се свързват с по-голям шанс за наша победа.

Match_VenueAway (три звездички ***): Мястото на провеждане на мача е супер значимо. Пред числото обаче има **минус** (-0.3405). Това ни казва нещо много логично – когато отборът гостува (**Away**), шансът (вероятността) за победа **намалява сериозно** в сравнение с домакинските мачове.

Rec_Perf (една звездичка *): Променливата за посрещане също е значима (макар и по-слабо от другите две). Минусът пред нея (-0.0074) показва, че има леко отрицателно влияние в модела.

(Intercept) (няма звездички): Свободният член вече не е значим, което е напълно нормално за сложни модели и не ни притеснява. Информационният критерий на Akaike за този модел е **AIC = 7218.6**

Оценка на качеството и сравнение чрез AIC:

- AIC на Модел 1 (простия) беше: 7254.8
- AIC на Модел 2 (сложния) сега е: 7218.6

- **Изводът:** Тъй като при Модел 2 стойността на AIC е паднала надолу (намаляла е с цели 36.2 единици), това е математическото доказателство, че Модел 2 е по-качественият, по-точният и по-добрият модел. Добавянето на информацията за гостуване/домакинство и посрещане значително е подобрило способността на регресията да предсказва правилно победите и загубите.

Прогнози с помощта на простия модел

```
blr_pred <- predict(object = model1, newdata = df, type = "response")

min_aces <- min(df$Opponent_Aces, na.rm = TRUE)
max_aces <- max(df$Opponent_Aces, na.rm = TRUE)

XX <- data.frame(Opponent_Aces = seq(from = min_aces, to = max_aces, by = 0.1))


probability_curve <- predict(object = model1, newdata = XX, type = "response")

y_factor <- as.factor(df$Is_Winner)

plot(df$Opponent_Aces, as.numeric(y_factor) - 1,
     xlab = "Opponent Aces",
     ylab = "Is Winner",
     main = "Probability curve",
     pch = 16, col = "darkgreen", yaxt = "n")

axis(2, at = c(0, 1), labels = c("No", "Yes"))

lines(XX$Opponent_Aces, probability_curve, col = "red", lwd = 2)
```



Какво представляват зелените точки: Наличието на зелени точки най-долу (при линията "No") и най-горе (при линията "Yes") показва реалните изиграни мачове от

твоя датасет. Вижда се как мачовете са разпределени по оста X спрямо това колко асове е направил опонентът.

Какво ни показва червената линия: Това е изчислената от логистичния модел вероятност. Тъй като линията плавно **се изкачва нагоре** от ляво на дясно, тя ни дава следното визуално доказателство:

С увеличаването на броя асове на противника (придвижвайки се надясно по оста X), червената линия се вдига нагоре по оста Y, което означава, че **вероятността за победа нараства**.

Защо линията изглежда почти права, а не като рязка "S"-крива: Тъй като коефициентът на променливата е сравнително малък ($\beta_1 = 0.0072$), промяната във вероятността се случва плавно и постепенно в рамките на наличните данни (от 0 до около 115 аса). Моделът умишлено не прави резки скокове, а показва стабилно и последователно покачване на шанса за победа, гарантирайки, че прогнозата винаги остава сигурно заключена между 0 и 1 (т.е. между "No" и "Yes").

Прогнози с помощта на сложния модел

```
coeffs1 <- model1$coefficients

Z1 <- round(coeffs1[[1]], 4) + round(coeffs1[[2]], 4) * df[, "Opponent_Aces"]

Probab1 <- round(1 / (1 + exp(-Z1)), 4)

result_DF1 <- data.frame(Z = Z1, Probab = Probab1, Is_Winner = as.character(df[, "Is_Winner"]))
result_DF1 <- result_DF1[order(result_DF1[, "Z"], decreasing = FALSE), ]

xtable1 <- paste0("Z = ", round(coeffs1[[1]], 4), " + ", round(coeffs1[[2]], 4), "*Opponent_Aces")

coeffs2 <- model2$coefficients

venue_numeric <- ifelse(df[, "Match_Venue"] == "Away", 1, 0)

Z2 <- round(coeffs2[[1]], 4) +
  round(coeffs2[[2]], 4) * df[, "Opponent_Aces"] +
  round(coeffs2[[3]], 4) * df[, "Rec_Perf"] +
  round(coeffs2[[4]], 4) * venue_numeric

Probab2 <- round(1 / (1 + exp(-Z2)), 4)

result_DF2 <- data.frame(Z = Z2, Probab = Probab2, Is_Winner = as.character(df[, "Is_Winner"]))
result_DF2 <- result_DF2[order(result_DF2[, "Z"], decreasing = FALSE), ]

xtable2 <- paste0("Z = ", round(coeffs2[[1]], 4), " + ", round(coeffs2[[2]], 4), "*Aces + ",
  round(coeffs2[[3]], 4), "*Rec + ", round(coeffs2[[4]], 4), "*Venue")
n <- length(model1$y)

L_null1 <- as.numeric(logLik(glm(Is_Winner ~ 1, data = df, family = "binomial")))
L_mod1 <- as.numeric(logLik(model1))
```



```

r2_cox1 <- 1 - exp((2/n) * (L_null1 - L_mod1))
model1_pseudo_r1 <- round(r2_cox1 / (1 - exp((2/n) * L_null1)), 4)

L_null2 <- as.numeric(logLik(glm(Is_Winner ~ 1, data = df, family = "binomial")))
L_mod2 <- as.numeric(logLik(model2))
r2_cox2 <- 1 - exp((2/n) * (L_null2 - L_mod2))
model1_pseudo_r2 <- round(r2_cox2 / (1 - exp((2/n) * L_null2)), 4)

par(mfrow = c(1, 2))

y_numeric1 <- ifelse(result_DF1$Is_Winner == "Yes", 1, 0)
plot(result_DF1[, "Z"], y_numeric1, xlab = xlable1, ylab = "Is Winner",
     main = "Probability curve (Model 1)", pch = 16, col = "darkgreen", yaxt = "n")
axis(2, at = c(0, 1), labels = c("No", "Yes"))


text(mean(Z1), 0.5, paste("Nagelkerke R2 =", model1_pseudo_r1), col="darkred", font=2)
lines(result_DF1[, "Z"], result_DF1[, "Probab"], col = "red", lwd = 2)

y_numeric2 <- ifelse(result_DF2$Is_Winner == "Yes", 1, 0)
plot(result_DF2[, "Z"], y_numeric2, xlab = xlable2, ylab = "Is Winner",
     main = "Probability curve (Model 2)", pch = 16, col = "blue", yaxt = "n")
axis(2, at = c(0, 1), labels = c("No", "Yes"))

text(mean(Z2), 0.5, paste("Nagelkerke R2 =", model1_pseudo_r2), col="darkred", font=2)
lines(result_DF2[, "Z"], result_DF2[, "Probab"], col = "red", lwd = 2)

par(mfrow = c(1, 1))

```



Визуалното сравнение между двата модела ясно показва превъзходството на **Модел 2 (сложния модел)**. От една страна, неговата червена вероятностна крива е по-стръмна, което означава, че моделът по-категорично разграничава шансовете за победа и загуба.

От друга страна, стойността на **Nagelkerke R^2** нараства от **0.0166** при първия модел до **0.0266** при втория. Този ръст, в комбинация с по-ниския AIC критерий, който установихме по-рано, е окончателното математическо доказателство, че включването на допълнителните фактори (качество на посрещането и място на провеждане на мача) подобрява качеството на прогнозите и прави втория модел по-точния избор за анализ.

Заклучение

Основната цел на този проект беше да изследва ключовите фактори, влияещи върху крайния изход от волейболните мачове (**Is_Winner**), и да разработи надежден статистически модел за прогнозиране на вероятността за победа.

Първоначалният проучвателен анализ на данните разкри няколко важни наблюдения:

- **Парадокс при противниковия сервис:** Тестът на Уилкоксън и сравнителният boxplot показаха статистически високосзначима разлика в броя на допуснатите асове. При спечелените мачове отборът парадоксално е допуснал по-висок брой асове от противника (медиана 66) в сравнение със загубените мачове (медиана 56), което подсказва за по-дълги и оспорвани срещи.
- **Влияние на фактора терен и играта в дефанзива:** Анализът установи, че качеството на посрещането (**Rec_Perf**) и мястото на провеждане на мача (**Match_Venue**) са критични определящи фактори. Гостуванията очаквано намаляват шансовете за успех, отразявайки психологическото и логистично предимство на домакина.

Предвид бинарния характер на крайния резултат (Победа/Загуба), фокусът ни се премести към разработването на надежден прогнозен модел чрез **Бинарна логистична регресия (BLR)**. Оценихме и сравнихме два модела:

- **Модел 1 (Прост):** Включващ само **Opponent_Aces**. Той доказва значимостта на предиктора и неговия положителен ефект ($\beta_1 = 0.0072$), постигайки **AIC: 7254.8** и **Nagelkerke $R^2 = 0.0166$** .
- **Модел 2 (Сложен):** Включващ три предиктора едновременно. Този модел се оказва по-информативен, като коефициентът за гостуване (**Match_VenueAway**) демонстрира силно и значимо отрицателно влияние върху шанса за победа ($\beta = -0.3405$).

Подробният сравнителен и диагностичен анализ разкри ключови прозрения за качеството на моделирането:

При Модел 2 стойността на критерия на Akaike намаля до **AIC: 7218.6** (с 36.2 единици по-малко), а обяснената променливост нарасна до **Nagelkerke $R^2 = 0.0266$** . Това е категорично математическо доказателство, че добавянето на факторите за гостуване и посрещане подобрява качеството на регресията. Визуалната проверка на вероятностните криви потвърди, че Модел 2 притежава по-стръмна и динамична S-крива, което му позволява по-успешно да разграничава условията, водещи до победа или загуба.

В заключение, крайният изход от волейболните срещи е предсказуем въз основа на технически и ситуационни фактори. Макар демографските и тактически елементи да са комплексни, тяхното влияние е уловено успешно от математическия апарат. **Модел 2 е окончателният ни и по-правилен избор** за практически анализ поради по-високата си предсказателна сила.